

Régression Quantile pour l'Estimation de la VaR

Approches Linéaires, Non-Paramétriques et Extensions

Projet ML for Finance

Décembre 2025

Résumé

Ce document présente un état de l'art de la **régression quantile** appliquée à l'estimation de la Value-at-Risk. La régression quantile permet l'estimation directe de quantiles conditionnels sans hypothèse distributionnelle via la minimisation d'une fonction de perte asymétrique (pinball loss). Nous couvrons les fondements théoriques, algorithmes d'optimisation, extensions non-paramétriques (arbres, random forests, gradient boosting machines), régularisation, et extensions dynamiques (CAViaR).

Table des matières

1	Introduction	3
1.1	Context et motivation	3
1.2	Avantages fondamentaux	3
2	Fondements Théoriques	3
2.1	Du paradigme classique au paradigme quantile	3
2.1.1	Régression classique	3
2.1.2	Régression quantile	3
2.2	Fonction de perte : Pinball Loss	3
2.3	Problème d'optimisation empirique	4
3	Application à l'Estimation de la VaR	4
3.1	Formulation	4
3.2	Variables explicatives	4
3.3	Algorithme d'estimation	4
4	Méthodes d'Estimation	5
4.1	Programmation Linéaire	5
4.2	Descente de Gradient	5
5	Extensions Non-Paramétriques	5
5.1	Motivation	5
5.2	Arbres de Régression Quantile	5
5.3	Random Forests Quantile	6
5.4	Gradient Boosting Machines (GBM)	6

6	Régularisation	6
6.1	LASSO Quantile	6
6.2	Ridge Quantile	6
6.3	Elastic Net	6
7	Extensions Dynamiques : CAViaR	7
7.1	Modèle CAViaR	7
7.2	Variantes	7
7.2.1	Symmetric Absolute Value	7
7.2.2	Asymmetric Slope	7
7.2.3	Adaptive	7
7.3	Estimation	7

1 Introduction

1.1 Context et motivation

Les méthodes traditionnelles d'estimation de la VaR (Variance-Covariance, Simulation Historique, Monte-Carlo, GARCH) présentent des limitations importantes : hypothèses distributionnelles restrictives, estimation indirecte en deux étapes, difficulté à intégrer des facteurs de risque multiples.

La régression quantile, introduite par Koenker et Bassett (1978), révolutionne ce paradigme en permettant l'**estimation directe** du quantile conditionnel sans modéliser la distribution complète.

1.2 Avantages fondamentaux

- **Estimation directe** : Modélise $q_\tau(Y|X)$ directement
- **Sans hypothèse distributionnelle** : Aucune hypothèse sur $F(Y|X)$
- **Robustesse** : Propriété intrinsèque aux outliers
- **Flexibilité** : Extensions non-paramétriques naturelles
- **Interprétabilité** : Coefficients ont sens économique clair

2 Fondements Théoriques

2.1 Du paradigme classique au paradigme quantile

2.1.1 Régression classique

La régression linéaire OLS modélise l'espérance conditionnelle :

$$\mathbb{E}[Y|X = x] = \beta^\top x \quad (1)$$

Estimateur : $\hat{\beta}_{OLS} = \arg \min_{\beta} \sum_{i=1}^n (y_i - \beta^\top x_i)^2$

Limitation La VaR est un **quantile**, pas l'espérance. Modéliser $\mathbb{E}[Y|X]$ ne donne aucune information directe sur $q_\tau(Y|X)$.

2.1.2 Régression quantile

Définition 1. Pour $\tau \in (0, 1)$, la régression quantile modélise le τ -quantile conditionnel :

$$q_\tau(Y|X = x) = \beta_\tau^\top x \quad (2)$$

Exemple 1. — $\tau = 0.05$: 5e percentile (VaR 95%)

- $\tau = 0.50$: médiane
- $\tau = 0.95$: 95e percentile

2.2 Fonction de perte : Pinball Loss

Définition 2 (Pinball Loss).

$$\rho_\tau(u) = u \cdot (\tau - \mathbb{1}_{u < 0}) = \begin{cases} \tau \cdot u & \text{si } u \geq 0 \\ (\tau - 1) \cdot u & \text{si } u < 0 \end{cases} \quad (3)$$

Pour VaR 95% ($\tau = 0.05$) :

- Si $u > 0$: pénalité = $0.05 \times u$
- Si $u < 0$: pénalité = $0.95 \times |u|$

La sous-estimation est pénalisée 19 fois plus, forçant l'estimateur vers le bon quantile.

Théorème 1. *Le τ -quantile minimise l'espérance de la pinball loss :*

$$q_\tau = \arg \min_{q \in \mathbb{R}} \mathbb{E}[\rho_\tau(Y - q)] \quad (4)$$

2.3 Problème d'optimisation empirique

Proposition 1. *Étant donné $\{(x_i, y_i)\}_{i=1}^n$, l'estimateur est :*

$$\hat{\beta}_\tau = \arg \min_{\beta \in \mathbb{R}^p} \sum_{i=1}^n \rho_\tau(y_i - \beta^\top x_i) \quad (5)$$

3 Application à l'Estimation de la VaR

3.1 Formulation

Pour VaR 95% : $\text{VaR}_{0.05} = -q_{0.95}(r_{t+1}|\mathcal{F}_t)$

En pratique, on modélise directement les pertes ($L_t = -r_t$) :

$$q_\alpha(L_{t+1}|\mathcal{F}_t) = \beta_0 + \beta_1 r_t + \dots + \beta_p r_{t-p+1} + \gamma^\top z_t \quad (6)$$

3.2 Variables explicatives

TABLE 1 – Features pour régression quantile VaR

Catégorie	Variables
Rendements passés	r_{t-1}, \dots, r_{t-10}
Volatilité réalisée	$\sigma_t = \sqrt{\sum_{i=1}^{20} r_{t-i}^2}$
Volatilité proxy	$r_{t-1}^2, r_{t-2}^2, \dots$
Volume	$\ln(\text{Vol}_t), \Delta \ln(\text{Vol}_t)$
Macro	VIX, taux 10Y, spreads

3.3 Algorithme d'estimation

Algorithm 1 VaR par Régression Quantile

Require: Rendements $\{r_t\}$, α , V_0

- 1: Construire features : $X_t = (1, r_{t-1}, \dots, r_{t-10}, \sigma_t)$
 - 2: Split temporel : Train (70%), Test (30%)
 - 3: Estimer : $\hat{\beta}_\tau \leftarrow \arg \min \sum \rho_\tau(y_i - \beta^\top x_i)$
 - 4: Prédire : $\hat{q}_{\tau,t} \leftarrow \hat{\beta}_\tau^\top x_t$
 - 5: VaR : $\widehat{\text{VaR}}_{\alpha,t} \leftarrow -\hat{q}_{\tau,t} \cdot V_0$
 - 6: Backtesting : Tests Kupiec, Christoffersen
 - 7: **return** VaR_α
-

4 Méthodes d'Estimation

4.1 Programmation Linéaire

Le problème peut être reformulé comme LP en introduisant variables d'écart $u^+, u^- \geq 0$:

$$\min \quad \tau \mathbf{1}^\top u^+ + (1 - \tau) \mathbf{1}^\top u^- \quad (7)$$

$$\text{s.c.} \quad \mathbf{y} = \mathbf{X}\beta + u^+ - u^- \quad (8)$$

$$u^+, u^- \geq 0 \quad (9)$$

Solveurs Simplex (MATLAB, R `quantreg`), Interior-point, Python `statsmodels`

4.2 Descente de Gradient

Le sous-gradient de ρ_τ est :

$$\partial \rho_\tau(u) = \tau - \mathbb{I}_{u < 0} \quad (10)$$

Algorithm 2 SGD pour Régression Quantile

```
1: Initialiser  $\beta^{(0)}$ 
2: for  $k = 1$  to  $K$  do
3:   for  $i = 1$  to  $n$  do
4:      $u_i \leftarrow y_i - \beta^{(k)\top} x_i$ 
5:      $g_i \leftarrow -x_i \cdot (\tau - \mathbb{I}_{u_i < 0})$ 
6:      $\beta^{(k)} \leftarrow \beta^{(k)} - \eta_k g_i$ 
7:   end for
8: end for
9: return  $\beta^{(K)}$ 
```

5 Extensions Non-Paramétriques

5.1 Motivation

Le modèle linéaire suppose effets linéaires et additifs. Les marchés présentent :

- Non-linéarités complexes
- Interactions entre variables
- Seuils et régimes

5.2 Arbres de Régression Quantile

Un arbre partitionne \mathcal{X} en régions. Chaque feuille prédit le quantile empirique.

Définition 3.

$$\hat{q}_\tau(x) = \sum_{m=1}^M c_m \mathbb{I}_{x \in R_m} \quad (11)$$

où $c_m = \text{Quantile}_\tau(\{y_i : x_i \in R_m\})$

5.3 Random Forests Quantile

Combiner B arbres bootstrap :

$$\hat{q}_\tau(x) = \text{Quantile}_\tau\{\hat{f}_1(x), \dots, \hat{f}_B(x)\} \quad (12)$$

5.4 Gradient Boosting Machines (GBM)

Construction séquentielle : chaque arbre corrige les erreurs du précédent.

$$\hat{f}_M(x) = \sum_{m=0}^M \nu \cdot h_m(x) \quad (13)$$

Algorithm 3 GBM Quantile

```
1:  $\hat{f}_0(x) \leftarrow \text{Quantile}_\tau(\{y_1, \dots, y_n\})$ 
2: for  $m = 1$  to  $M$  do
3:   Calculer pseudo-résidus :  $r_i \leftarrow \tau - \mathbb{I}_{y_i < \hat{f}_{m-1}(x_i)}$ 
4:   Ajuster arbre :  $h_m \leftarrow \text{FitTree}(\{(x_i, r_i)\})$ 
5:    $\hat{f}_m(x) \leftarrow \hat{f}_{m-1}(x) + \nu \cdot h_m(x)$ 
6: end for
7: return  $\hat{f}_M$ 
```

Hyperparamètres typiques

- Profondeur : 3-8
- Learning rate : 0.01-0.1
- N estimators : 500-1000 avec early stopping

6 Régularisation

6.1 LASSO Quantile

Pénalité L^1 pour sélection de variables :

$$\hat{\beta}_\tau^{\text{LASSO}} = \arg \min_{\beta} \left[\sum \rho_\tau(y_i - \beta^\top x_i) + \lambda \|\beta\|_1 \right] \quad (14)$$

Certains β_j deviennent exactement zéro (sparsité).

6.2 Ridge Quantile

Pénalité L^2 pour stabilité :

$$\hat{\beta}_\tau^{\text{Ridge}} = \arg \min_{\beta} \left[\sum \rho_\tau(y_i - \beta^\top x_i) + \lambda \|\beta\|_2^2 \right] \quad (15)$$

6.3 Elastic Net

Combinaison :

$$\lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2 \quad (16)$$

7 Extensions Dynamiques : CAViaR

7.1 Modèle CAViaR

Conditional Autoregressive VaR (Engle & Manganelli, 2004) :

$$\text{VaR}_t = f(\text{VaR}_{t-1}, \mathcal{F}_t; \beta) \quad (17)$$

7.2 Variantes

7.2.1 Symmetric Absolute Value

$$\text{VaR}_t = \beta_0 + \beta_1 \text{VaR}_{t-1} + \beta_2 |r_{t-1}| \quad (18)$$

7.2.2 Asymmetric Slope

$$\text{VaR}_t = \beta_0 + \beta_1 \text{VaR}_{t-1} + \beta_2 r_{t-1}^+ + \beta_3 r_{t-1}^- \quad (19)$$

7.2.3 Adaptive

$$\text{VaR}_t = \text{VaR}_{t-1} + \beta [\mathbb{1}_{r_{t-1} < \text{VaR}_{t-1}} - \alpha] \quad (20)$$

7.3 Estimation

Minimiser :

$$\hat{\beta} = \arg \min_{\beta} \sum_{t=1}^T \rho_{\alpha}(r_t - \text{VaR}_t(\beta)) \quad (21)$$

Optimisation non-convexe : Nelder-Mead, algorithmes génétiques.

Références

- [1] Koenker, R., & Bassett Jr, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33-50.
- [2] Engle, R. F., & Manganelli, S. (2004). CAViaR : Conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367-381.
- [3] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- [4] Friedman, J. H. (2001). Greedy function approximation : A gradient boosting machine. *Annals of Statistics*, 29(5), 1189-1232.
- [5] Chen, T., & Guestrin, C. (2016). XGBoost : A scalable tree boosting system. *KDD 2016*.
- [6] Taylor, J. W. (2019). Forecasting value at risk and expected shortfall. *Journal of Business & Economic Statistics*, 37(1), 121-133.
- [7] Koenker, R. (2005). *Quantile Regression*. Cambridge University Press.
- [8] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.